Executive Essay: TravelTide Rewards-Personalisierung via Segmentierung und Perk-Zuweisung

Kontext und Ziel

TravelTide möchte die Kundenbindung durch ein personalisiertes Rewards-Programm verbessern. Zentraler Hebel ist eine Einladungskommunikation, die pro Nutzer das wahrscheinlich attraktivste Reward-Element hervorhebt (z. B. kostenlose Stornierung, Discounts, Hotel-Perk). Ziel des Projekts war daher zweigeteilt: (1) in den Daten nachweisbare Verhaltensmuster identifizieren, die mit unterschiedlichen Perk-Präferenzen vereinbar sind, und (2) für jeden Nutzer eine favorisierte Perk-Zuweisung ableiten, die sich nachvollziehbar begründen lässt.

---

1) SQL: Kohortendefinition und Extraktion

Warum eine Kohorte und warum "> 7 Sessions"?

Für verhaltensbasierte Personalisierung gilt: zu wenig Daten pro Nutzer → Personalisierung wird Zufall. Ein einzelnes Session-Verhalten ist stark situationsabhängig (z. B. spontanes Stöbern vs. konkrete Buchungsabsicht) und liefert kaum stabile Signale. Daher wurde eine Kohorte gewählt, die genügend Interaktionen pro Nutzer enthält, um robuste Kennzahlen (Median/Anteile über Sessions/Trips) zu berechnen.

Die Vorgabe „mehr als 7 Sessions" (also ≥ 8 Sessions) erfüllt genau diesen Zweck: Sie stellt sicher, dass pro Nutzer ausreichend Sessions vorliegen, um z. B. einen stabilen Median der Sessiondauer oder einen verlässlichen Anteil an Cancellation-Sessions zu berechnen. Im Datensatz ergab dies eine Kohorte von 5.998 Nutzern und 49.211 Sessions, wobei die Sessionanzahl pro Nutzer in dieser Kohorte eng begrenzt ist (Median 8, Maximum 12). Das reduziert außerdem die Verzerrung durch extrem aktive Power-User, die einzelne Segmente dominieren könnten.

Warum Startdatum 2023-01-04?

Das Datum folgt dem Stakeholder-Vorschlag, eine zeitlich konsistente Beobachtungsperiode zu nutzen. Ohne Zeitfenster würden Nutzer mit sehr langer Plattformhistorie mit neuen Nutzern vermischt; Verhalten ändert sich aber systematisch mit der "Tenure" (Erfahrung mit

der Plattform, veränderte Reisegewohnheiten, Saisonalität). Ein fixes Startdatum schafft Vergleichbarkeit und reduziert zeitbedingte Biases.

Ergebnis der SQL-Phase

Die SQL-Extraktion erzeugte eine Session-Level-Datei (CSV), die Sessions, Buchungsflags, Discounts, sowie Flight- und Hotel-bezogene Attribute über trip_id zusammenführt. Diese Session-Basis ist die notwendige Grundlage für alle folgenden Bereinigungs-, Aggregations- und Feature-Schritte.

2) Python: Pipeline, Bereinigung und Feature Engineering

Arbeitsweise und eingesetzte Tools

Die Python-Arbeit erfolgte in Colab (reproduzierbar, gut teilbar, CSVs im Drive). Zentrale Werkzeuge:

- pandas / numpy für Datenhandling, Aggregationen und Feature Engineering
- matplotlib für Visualisierungen
- scikit-learn für Skalierung (StandardScaler) und Clustering (KMeans) sowie Metriken
- Speicherung von Zwischenergebnissen als CSV (processed folder), um die Pipeline auch nach Runtime-Reset stabil fortsetzen zu können

Datenbereinigung (GIGO-Prinzip)

Mehrere QC-Schritte wurden durchgeführt, um ein “sauberes Datenpaket” zu erzeugen:

1. Hotel-Nights-Anomalien (≤ 0)
   Nights-Werte von 0 oder negativ sind als Aufenthaltsdauer nicht plausibel. Statt diese Zeilen pauschal zu löschen (Datenverlust) wurden Nights aus Check-in/Check-out abgeleitet (“inferred nights”).

   - Falls eine positive Differenz berechenbar war, wurde hotel_nights_clean korrigiert.
   - Falls keine sinnvolle Ableitung möglich war, wurde der Wert auf Missing gesetzt.

2. Outlier-Behandlung (Winsorizing)
   Statt harte Filter (die viele Nutzer vollständig entfernen könnten) wurde eine winsorisierte Variante erstellt: numerische Extremwerte wurden auf das 1%- bzw.

99%-Quantil begrenzt. Diese Entscheidung wurde gegen IQR-Logik geprüft (Boxplot-Idee) und bewusst gewählt, weil sie (a) robust gegenüber Heavy Tails ist und (b) Datenpunkte nicht entfernt, sondern nur extreme Skalenwirkung reduziert – wichtig für Distanzverfahren wie KMeans.

3. Typkonvertierung und Normalisierung
   Booleans wurden konsistent normalisiert, Datumsfelder als Datetime interpretiert, numerische Spalten coercion-sicher konvertiert.
4. Missingness-Strategie (Imputation mit Logik)
   Missing Values wurden nicht “blind” ersetzt, sondern kontextabhängig:

   - Nutzer ohne Flight-Trips: flight-basierte Metriken wurden auf 0 gesetzt (keine Flüge → keine Discounts/Distance/Savings).
   - Nutzer ohne Hotel-Trips: hotel-basierte Metriken wurden auf 0 gesetzt (keine Hotels → keine Nights/Rate).
     Ziel: Clustering und Scoring sollen mit vollständigen Matrizen arbeiten können, ohne dass Missingness selbst zum dominanten Signal wird.

3) Clustering: Vorgehen und Begründung

Feature Set und Skalierung

Das Clustering wurde auf einem Feature Set durchgeführt, das perk-nahe Verhaltensdimensionen enthält (Discount-/Deal-Signale, Hotel-Intensität, Gepäck/Seats, Cancellation/Engagement). Da KMeans distanzbasiert ist, wurden die Features mittels StandardScaler skaliert (Mean ~0, Std ~1).

Wahl von k und Stabilität

Die Clusterzahl wurde nicht willkürlich gewählt. Es wurden mehrere k-Werte evaluiert:

- Inertia/Elbow als Komplexitäts-Tradeoff
- Silhouette Score als Trennschärfe-Indikator
  Zusätzlich wurde die Robustheit über verschiedene Seeds geprüft (Adjusted Rand Index), mit hoher durchschnittlicher Übereinstimmung (~0,87). Daraus wurde k = 4 als gute Balance aus Interpretierbarkeit und Stabilität übernommen.

Rolle von PCA

PCA wurde unterstützend genutzt, um Cluster in 2D zu visualisieren und grobe Trennbarkeit zu prüfen (ohne PCA als zwingenden Modellschritt zu behandeln). Die ersten zwei Komponenten erklärten zusammen rund die Hälfte der Varianz (~0,51), was als plausibel für eine Verdichtung vieler Verhaltensdimensionen gilt.

4) Durchschnitts-Personas je Cluster (Steckbrief, Medianwerte)

Die folgenden Kennzahlen sind Medianwerte je Cluster (komprimierter Steckbrief). cluster_pct beschreibt den Anteil der Nutzer in der Kohorte.

Cluster 0 (8,55% | n=513) – Discount-orientiert

- Sessions: 8 | Sessiondauer: 89s | Klicks: 12 | Cancellation: 0%
- Flights: 2 | Discount-Frequenz: 0,50 | Avg Discount: 0,18 | Bargain Index: 0,01
- Seats: 2 | Checked Bags: 1
- Hotels: 2 | Nights: 2,5 | Rate: 160 | Hotel-Kosten (est.): 1.110

Cluster 1 (45,88% | n=2.752) – Value-orientiert (moderat)

- Sessions: 8 | Sessiondauer: 72,5s | Klicks: 10 | Cancellation: 0%
- Flights: 1 | Discount-Frequenz: 0,00 | Avg Discount: 0,00
- Seats: 1 | Bags: 0
- Hotels: 1 | Nights: 2,5 | Rate: 129 | Hotel-Kosten (est.): 658

Cluster 2 (9,34% | n=560) – Flex/Indecision gemischt

- Sessions: 8 | Sessiondauer: 131,25s | Klicks: 17,25 | Cancellation: 12,5%
- Flights: 3 | Discount-Frequenz: 0,50 | Avg Discount: 0,00
- Seats: 3 | Bags: 2
- Hotels: 2 | Nights: 3,0 | Rate: 146 | Hotel-Kosten (est.): 1.594

Cluster 3 (36,23% | n=2.173) – Hotel-/Trip-intensiv, Value-getrieben

- Sessions: 8 | Sessiondauer: 129s | Klicks: 17,5 | Cancellation: 0%
- Flights: 4 | Discount-Frequenz: 0,00 | Avg Discount: 0,00
- Seats: 4 | Bags: 2
- Hotels: 4 | Nights: 2,5 | Rate: 154 | Hotel-Kosten (est.): 2.113

5) Perk-Zuweisung: Scoring-Logik und Begründung

Warum Scoring statt “Cluster = Perk”?

Cluster dienen als Archetypen zur Interpretation. Die tatsächliche Rewards-Personalisierung soll jedoch auf Nutzer-Ebene erfolgen, weil innerhalb eines Clusters relevante Untergruppen existieren (z. B. Cluster 1 enthält neben “Free night”-Affinen auch Bag- und Cancellation-affine Nutzer). Scoring ermöglicht eine feinere Zuordnung, ohne die Segment-Story zu verlieren.

Wie funktionieren die Scores?

Für jeden Nutzer wurden pro Perk Score-Komponenten berechnet und auf 0–1 normalisiert (MinMax). Beispiele:

- Exclusive Discounts: Kombination aus Discount-Häufigkeit, durchschnittlicher Discount-Höhe, Dollars-saved-per-km (skaliert), Bargain Index.
- No Cancellation Fees: hoher Cancellation-Anteil + lange Sessions + viele Klicks (Indecision-/Flexibilitätssignal).
- Free Checked Bag: Bags pro Seat + Seats (Gruppensignal) + Kinderindikator (Familiennähe).
- Free Hotel Meal: Hotel-Intensität (Trips), längere Aufenthalte (Nights), höheres Preisniveau (Rate).
- 1 Night Free Hotel with Flight: Hotel-Intensität + Stay-Länge + “Value”-Signal über niedrigere Hotelrate + Deal-Orientierung.

Der Perk mit dem höchsten Score wird zugewiesen.

Warum Eligibility/Gating?

Ein wichtiger Qualitäts-Schritt war, Perks nur dann “gewinnbar” zu machen, wenn entsprechende Verhaltensdaten existieren:

- Hotel-Perks nur bei hotel_trips_count > 0
- Discounts/Bag nur bei flight_trips_count > 0, Bag zusätzlich nur bei seats_sum > 0
- Cancellation-Perk nur bei pct_cancellation_sessions > 0

Damit wird verhindert, dass ein Perk durch Imputation (z. B. Hotelrate = 0 bei Nicht-Hotel-Nutzern) künstlich Vorteile erhält. Nach Gating ergibt sich eine plausiblere Gesamtverteilung (u. a. steigt “no_cancellation_fees” deutlich).

Ergebnis: Perk-Verteilung je Cluster (Top-Perk-Anteile)

- Cluster 0: exclusive_discounts (49,9%)
- Cluster 1: one_night_free_hotel_with_flight (56,5%)
- Cluster 2: one_night_free… (33,9%) knapp vor no_cancellation_fees (32,3%) → idealer A/B-Test-Kandidat
- Cluster 3: one_night_free… (73,8%)

Fazit und Empfehlung

Fazit

Das Projekt liefert eine reproduzierbare Pipeline von SQL-Extraktion über Bereinigung, Feature Engineering, stabile Segmentierung (k=4) und nachvollziehbare Perk-Zuweisung pro Nutzer. Die Segmente sind interpretierbar (Discount-, Value-, Flex-/Indecision-, Intensiv-Reisende), und die Perks sind datenbasiert abgeleitet statt rein intuitiv vergeben.

Live-Test: KPIs und Experimentdesign

Um den Erfolg nach Launch zu prüfen, sollten Metriken entlang einer klaren Wirkungskette gemessen werden:

E-Mail / Rewards Signup (kurzfristig)

- Open Rate, CTR (Call-to-Action)
- Signup-Rate Rewards-Programm (Overall + je Perk + je Cluster)

Verhalten (mittel-/langfristig)

- Booking Conversion nach Email (z. B. 7/14/30 Tage)
- Wiederbuchung / Retention (30/60/90 Tage)
- Stornoquote nach Einführung (insbesondere für Cancellation-Perk)
- Durchschnittlicher Deckungsbeitrag pro Buchung (Profitabilität, nicht nur Umsatz)

Experimentempfehlung

- A/B-Test im Cluster 2: No cancellation fees vs. One night free (Top-2 nahezu gleich stark)
- Kontrollgruppe: generische Email ohne Perk-Personalisierung, um uplift zu messen

Skalierung / Ausbau

Das aktuelle Setup ist bewusst auf eine “datenstarke” Kohorte fokussiert. Ein realistischer Ausbau wäre:

1. **Schrittweise Kohortenerweiterung**

    - Test mit ≥5 Sessions (größer, aber noisiger) und Vergleich der Stabilität
    - Einführung eines “cold start”-Pfads: Nutzer mit wenigen Sessions erhalten zunächst eine konservative Default-Strategie (z. B. clusterbasierte Wahrscheinlichkeiten oder einfache Regeln), bis genug Daten vorliegen

2. **Score-Weiterentwicklung**

    - Gewichte datengetrieben nachjustieren (z. B. anhand der KPI-Uplifts pro Perk)
    - Ergänzende Features: Saisonalität, Reisedistanz-Profile, Return-Flight-Verhalten, Hotel-Comfort vs Budget

3. **Kosten-/ROI-Modell**

- Perk-Kosten gegenüber Retention-Uplift abbilden (z. B. free night ist teuer → gezielte Anwendung bei hoher erwarteter Wirkung)